

6. Métricas

Ejercicio 6.1. Métricas de regresión

Consideremos un problema de regresión en el cual entrenamos un modelo h sobre un conjunto de datos $\mathcal{D}$, obteniendo predicciones para cada instancia $\hat{y}^{(i)} = h(\mathbf{x}^{(i)})$.

- (a) Supongamos que aplicamos una transformación lineal de escala homogénea a las etiquetas y a las predicciones: $y^{\text{esc}} = a \cdot y + b$ y $\hat{y}^{\text{esc}} = a \cdot h(\mathbf{x}^{(i)}) + b$ (con $a > 0$). ¿Cómo afecta esta transformación al MAE y al MSE del modelo en $\mathcal{D}$?

- (b) Recordemos la definición del coeficiente de determinación:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y^{(i)} - h(\mathbf{x}^{(i)}))^2}{\sum_{i=1}^n (y^{(i)} - \bar{y})^2}$$

- (c) ¿Bajo qué condiciones R^2 toma su valor máximo ($R^2 = 1$) y cuándo vale exactamente 0?
- (d) ¿Bajo qué condición ocurre que ($R^2 < 0$)?
- (e) En el mismo escenario que el punto (a), ¿cómo se ve afectado el coeficiente de determinación R^2 de nuestro modelo en $\mathcal{D}$?
- (f) ¿Qué ventaja práctica fundamental presenta R^2 frente a MAE o MSE al comparar el desempeño de modelos entrenados sobre problemas con distintas unidades físicas (ej. precios en dólares vs. distancias en kilómetros)? ¿Cuál es su desventaja evidente?

- (g) **el caso de MAPE:**

En proyectos reales (como pronóstico de ventas o consumo eléctrico), reportar MAE o MSE suele generar fricción al comunicar resultados a áreas de negocio: si un producto vende 100 unidades al mes, error por 50 es inadmisibile; si vende 1.000.000, es una predicción excelente. Para independizarse del volumen de cada serie, la industria recurre al *Mean Absolute Percentage Error* (MAPE):

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \frac{|y^{(i)} - h(\mathbf{x}^{(i)})|}{|y^{(i)}|}$$

A pesar de su popularidad, MAPE presenta patologías matemáticas severas. Explique por qué las siguientes dos situaciones son indeseables:

- I. **Inestabilidad numérica:** ¿Qué sucede cuando existen instancias con $y^{(i)} = 0$ o valores muy cercanos a cero ($y^{(i)} \approx 0$)?
- II. **Asimetría intrínseca en la penalización:** Considerando un valor real fijo $y = 100$, calcule el porcentaje de error penalizado si el modelo subestima prediciendo $h(x) = 0$ frente a los casos en que sobreestima prediciendo $h(x) = 200$ y $h(x) = 300$. ¿Hacia qué sesgo sistemático en las predicciones empuja esta asimetría a un modelo entrenado para minimizar MAPE?

Ejercicio 6.2. Matriz de Confusión

- (a) En un problema de clasificación binaria, ¿a qué se denomina clase positiva y a qué clase negativa? Si nuestro problema consiste en clasificar spam vs. no-spam, ¿cuál es la clase positiva? Si nuestro problema es clasificar imágenes de perros vs. gatos, ¿cuál es la clase positiva?
- (b) Explicar con tus palabras la definición de *verdadero positivo*, *verdadero negativo*, *falso positivo* y *falso negativo*.
- (c) Completar la Primera Parte del notebook `notebook_metricas.ipynb`. El Test 1 debería pasar.
- (d) ¿Por qué podría un falso positivo ser considerado más (o menos) importante que un falso negativo? Dar un ejemplo en donde es más grave tener falsos negativos que falsos positivos.

Ejercicio 6.3. Métricas de umbral fijo

- (a) Explicar conceptualmente la definición de *accuracy*, *precision* y *recall*.
- (b) Completar la Segunda Parte del notebook `notebook_metricas.ipynb`. El Test 2 debería pasar.
- (c) ¿Por qué es problemático reportar únicamente *accuracy* en problemas con desbalance de clases?

(d) Recordemos la definición canónica del puntaje F_β como media armónica ponderada entre precisión y recall:

$$F_\beta = (1 + \beta^2) \cdot \frac{\text{Precision} \cdot \text{Recall}}{\beta^2 \cdot \text{Precision} + \text{Recall}}$$

Demuestre algebraicamente que puede reescribirse en términos de los elementos de la matriz de confusión como:

$$F_\beta = \frac{(1 + \beta^2) \cdot \text{TP}}{(1 + \beta^2) \cdot \text{TP} + \beta^2 \cdot \text{FN} + \text{FP}}$$

(e) Observe la fórmula de F_β deducida en el ítem anterior.

- I. ¿Aparece la cantidad de verdaderos negativos (TN) en dicha expresión?
 - II. Supongamos un escenario de detección de fraude donde hay 100 transacciones fraudulentas y 10.000 legítimas. Si agregamos 90.000 nuevas transacciones legítimas que el modelo clasifica correctamente como legítimas, ¿cómo varía el valor de F_1 ? ¿Tiene sentido que la métrica permanezca inalterada frente a un incremento masivo en la capacidad de descartar negativos?
 - III. A partir de esta limitación, ¿qué problema surge si intentamos comparar el desempeño de un clasificador entre dos poblaciones con distinta prevalencia de casos negativos?
- (f) Demuestre que la métrica recall, evaluada como función del umbral de decisión μ , es una función monótona no creciente:

$$\text{recall}_{h,D}(\mu_1) \leq \text{recall}_{h,D}(\mu_2) \quad \text{si } \mu_1 > \mu_2$$

(g) Muestre mediante un contraejemplo simple cómo la métrica precisión, evaluada como función del umbral de decisión μ , **no necesariamente** es monótona: es decir, puede ocurrir que $\text{precision}_{h,D}(\mu_1) > \text{precision}_{h,D}(\mu_2)$ aun cuando $\mu_1 < \mu_2$.

Ejercicio 6.4. Recordemos que un clasificador con salida continua asigna a cada instancia un *score* (puntaje numérico), tal como una probabilidad a posteriori estimada $\hat{P}(Y = 1|X) \in [0, 1]$, la distancia con signo al hiperplano en una SVM o un logit. Este valor refleja el grado de confianza o afinidad hacia la clase positiva y permite inducir un ordenamiento (*ranking*) sobre los datos. Al elegir un umbral μ , se predice positivo si $\text{score} \geq \mu$ y negativo en caso contrario, generando una matriz de confusión para cada corte.

Ejercicio 6.5. Considerar la Figura 7. En esta figura se ven instancias ordenadas según la probabilidad detectada por un clasificador (entre 0 y 1). Además, se encuentran marcados cuatro umbrales de decisión.

- (a) Calcular las tablas de confusión resultantes para cada uno de los cuatro umbrales de decisión. Recordar que si la probabilidad está por debajo del umbral, la instancia será clasificada como perteneciente a la clase negativa; si está por encima, como clase positiva.
- (b) ¿Cuál es el mejor umbral entre estos cuatro?
- (c) Con dichos umbrales, graficar cuatro puntos de la curva Precision-Recall para dicha clasificación.




Figura 7: Umbral de clasificación

Escribir el pseudocódigo de la siguiente función:

`CURVA-ROC(LABELS : LIST<BOOL>, SCORES : LIST<FLOAT>) : LIST<TUPLE<UMBRAL, FPR, TPR>>`

donde:

- `Labels` contiene las etiquetas verdaderas de cada instancia (`True` para la clase positiva, `False` para la negativa).
- `Scores` contiene los puntajes reales continuos predichos por el modelo para cada una de esas instancias.

La función debe retornar la lista de tuplas con el umbral explorado y sus correspondientes tasas de falsos positivos (FPR) y verdaderos positivos (TPR).

Tip: Notar que no hace falta evaluar infinitos umbrales continuos: basta con ordenar las instancias de mayor a menor según su score y evaluar los puntos de corte donde cambian las predicciones.

Ejercicio 6.6. Verdadero o Falso (justificar)

- (a) AUC-ROC es invariante de umbral de clasificación. Mide la calidad de las predicciones del modelo independientemente del umbral de clasificación elegido.
- (b) El AUC-ROC es invariante de escala (invariante a transformaciones lineales en las predicciones). Mide qué tan bien se clasifican las predicciones, en lugar de sus valores absolutos.
- (c) En caso que el ordenamiento de las instancias sea el mismo y suponiendo que no hay scores repetidos, AUC-ROC va poder distinguir un clasificador muy confiado (instancias clasificadas como positiva tienen scores muy altos, instancias clasificadas como negativas scores muy bajos) de uno poco confiado (scores menos extremos).

Ejercicio 6.7. En los casos en los que existen grandes disparidades en el costo de los falsos negativos frente a los falsos positivos, puede ser fundamental minimizar un tipo de error de clasificación. Por ejemplo, al detectar spam, es probable que desee priorizar la minimización de los falsos positivos (incluso si eso resulta en un aumento significativo de los falsos negativos). ¿Cuál de las siguientes métricas sería la más adecuada y por qué?

- Precision
- F_β con algún valor de β que favorezca precisión.
- AUC-ROC

Ejercicio 6.8. Sea A un clasificador que tiene un F_1 de 0.80 (con un umbral de clasificación de 0.5), y sea B un clasificador que tiene un F_1 0.70 (también con un umbral de clasificación de 0.5). Sin embargo al cambiar el umbral a 0.4 obtenemos F_1 de 0.76 y 0.80 respectivamente.

- (a) Explicar por qué puede suceder este fenómeno dando un ejemplo aproximado.
- (b) ¿Podemos concluir algo sobre el AUC Prec-Recall de estos dos modelos?

Ejercicio 6.9. Verdadero o Falso (justificar)

- (a) Tanto *recall* como *precision* no toman en cuenta qué tan bien el modelo maneja los casos negativos.
- (b) Un modelo que no produce falsos positivos tiene *precision* = 1.0.
- (c) Un modelo que no produce falsos negativos tiene *recall* = 1.0.
- (d) Si un clasificador devuelve probabilidades, la matriz de confusión se construye de manera ponderada según la probabilidad de cada clase.
- (e) Si un clasificador devuelve probabilidades, hay muchas matrices de confusión asociadas dependiendo del umbral de clasificación.
- (f) Si un clasificador devuelve probabilidades, hay infinitas matrices de confusión asociadas dependiendo del umbral de clasificación.
- (g) Aumentar el umbral de clasificación produce que la *precision* siempre suba.
- (h) Aumentar el umbral de clasificación produce que el *recall* baje o se mantenga igual.
- (i) La métrica *precision* es parte fundamental del cálculo de la *curva ROC*.

Ejercicio 6.10. ¿Binaria o 2 clases?

Sean A y B clasificadores que distinguen entre imágenes de perros e imágenes de gatos. Al medir la performance del clasificador (utilizando F_1 para evitar los problemas de utilizar *accuracy*) y “gato” como clase positiva, obtenemos $F_1(A) = 0.9$, $F_1(B) = 0.8$. ¿Podemos concluir que el clasificador A es mejor que el clasificador B para este problema?

Resolver los siguientes ítems para poder responder a la pregunta:

- (a) Al calcular F_1 utilizando “gato” como clase positiva, ¿importa qué ocurre con los perros que fueron clasificados correctamente? Revisar la Tercera Parte del notebook `notebook_metricas.ipynb` y decidir cuál clasificador funciona mejor, basándose en las métricas obtenidas. Observar el cambio que ocurre al intercambiar cuál es la clase positiva.

- (b) ¿Para qué sirve el parámetro `average` en la función `f1_score` de la librería `sklearn`?
- (c) ¿Qué sucede si la cantidad de instancias sobre las que fueron testeados es distinta? ¿Cómo se ve afectada la métrica F_1 al cambiar los True Negatives? Correr la Cuarta Parte del notebook `notebook_metricas.ipynb`. El gráfico muestra cómo varía la métrica F_1 al aumentar la cantidad de True Negatives (observar que estamos cambiando la cantidad de instancias sobre las que testeamos). ¿Qué se puede concluir de este experimento?

Ejercicio 6.11. Recordemos la métrica de *accuracy* para un problema de clasificación, para simplificar solo consideraremos el caso binario, sea y el vector de etiquetas verdadera, $\hat{y}$ las respectivas predicciones, y N la cantidad total de muestras ($y, \hat{y} \in \{0, 1\}^N$):

$$\text{accuracy}(y, \hat{y}) = \frac{1}{N} \sum_{i=1}^N 1(\hat{y}^{(i)} = y^{(i)})$$

Donde $1(x)$ es la función indicadora (vale 1 si el argumento es verdadero, 0 caso contrario). Vamos a introducir una pequeña modificación en como contamos los aciertos para cada clase, supongamos que p es la proporción de la clase minoritaria (positiva):

$$\text{balanced_accuracy}(y, \hat{y}) = \frac{1}{N} \left(\frac{1}{2p} \sum_{i=1}^N 1(\hat{y}^{(i)} = y^{(i)} = 1) + \frac{1}{2(1-p)} \sum_{i=1}^N 1(\hat{y}^{(i)} = y^{(i)} = 0) \right)$$

- (a) ¿Qué rango de valores posibles tiene esta métrica? ¿Cuánto vale esta métrica si tenemos un clasificador constante que predice siempre la clase mayoritaria $\hat{y} = 0$? ¿Y si predice siempre la clase minoritaria?
- (b) Escribir `balanced_accuracy` en términos de TP , FP , TN y FN .
- (c) Mostrar que en el caso binario, esta métrica es equivalente al promedio aritmético entre *sensitividad* (true positive rate) y la *especificidad* (true negative rate).

Ejercicio 6.12. (opcional) Dada la siguiente matriz de costos:

Costos =	Clases\Decisiones	<i>Ignorar</i>	<i>ReChequear</i>	<i>Operar</i>
	<i>Maligno</i>	100	5	0
	<i>Benigno</i>	0	15	50

Suponiendo que $\hat{P}$ es un modelo entrenado y calibrado que produce las siguientes probabilidades:

- (I) $\hat{P}(Y = \text{Maligno} | X = \mathbf{x}^{(1)}) = 0.3$
- (II) $\hat{P}(Y = \text{Maligno} | X = \mathbf{x}^{(2)}) = 0.99$
- (III) $\hat{P}(Y = \text{Maligno} | X = \mathbf{x}^{(3)}) = 0.01$

Indicar la decisión óptima para cada instancia.