

9. Ingeniería de Atributos

Ejercicio 9.1. Se tienen datos de un famoso sitio de compra/venta de inmuebles, y se nos pide estimar el valor de una propiedad en base a sus atributos continuos. Al normalizar los atributos utilizando la técnica de min-max notamos que la mayoría de los valores quedaron en cero (o muy cerca de cero) y sólo un valor quedó en 1.

- (a) Explicar qué puede haber ocurrido.
- (b) Explicar qué técnica alternativa utilizaría si se pensara que el atributo sigue una distribución normal.

Ejercicio 9.2. En un problema de clasificación, decidimos imputar los valores faltantes de un atributo utilizando la media del resto de los valores. Al comparar la performance de nuestro modelo entrenado contra la realidad (al llevarlo a producción) vemos que hubo una subestimación del error.

- (a) Explicar qué puede haber ocurrido.
- (b) Indique claramente en qué momento del proceso calcularía el valor a imputar (pensar en la partición desarrollo-control, y en validación cruzada con K-folds). Especificar qué valores se utilizarían para el cálculo.
- (c) ¿Con qué valor deberíamos imputar los valores faltantes que aparezcan en producción?

Ejercicio 9.3. Supongamos que tenemos un conjunto de datos de 2021 que contiene información sobre el precio y la ubicación de diferentes propiedades inmobiliarias en Capital Federal. Estamos interesados en predecir si la propiedad se vendió o no durante ese mismo año.

Dada la siguiente porción de la base de datos,

- Proponer 3 nuevas columnas que puedan aportar nueva información y ser útiles para el problema en cuestión que no se puedan deducir de las columnas actuales.
- Describa todas las transformaciones que te parecen necesarias para poder utilizar esta tabla en un algoritmo de KNN implementado en sklearn. Para cada transformación, ser concreto en cómo realizan esa transformación y de algún ejemplo.

Precio	Ubicación	Metros cuadrados	Habitaciones	Fecha de publicación	Baños
100000	Nuñez	80	2	20/10/2021	2
150000	Almagro	100	3	02/05/2021	N/A
200000	Caballito	N/A	2	N/A	1
N/A	N/A	120	N/A	03/09/2021	2

Tabla 3: Datos de propiedades

Ejercicio 9.4. Dados los siguientes problemas de clasificación, indique qué transformaciones aplicaría a los datos antes de utilizar el algoritmo de K-vecinos más cercanos. En caso de no tener que hacer transformaciones justificar por qué. Todos los atributos agregados deberán ser transformaciones de atributos ya existentes entre los datos.

- (a) Se quiere determinar si una persona utilizará una bicicleta de la ciudad para volver de su trabajo en base a: momento en el que salió del trabajo (timestamp que contiene fecha y hora), latitud y longitud en donde se encuentra su trabajo.
- (b) Se quiere determinar si una persona visitará o no el barrio chino el día de hoy. Para eso, tenemos el día (fecha completa), la temperatura (medida en grados) y la longitud y latitud en la que se encuentra. Suponer que hay una gran cantidad de gente que visita el barrio en el año nuevo.
- (c) Se quiere predecir la temperatura en función de la distancia en kilómetros a la montaña más cercana, la altitud y la cantidad de picos montañosos a menos de 10 kilómetros de la ciudad.
- (d) Se quiere determinar la raza de un perro en base a: color de ojos (azul, verde, gris, etc.), color del pelo predominante (marrón, verde, gris, etc.), y tamaño del animal (chico, mediano, grande)
- (e) Se quiere determinar si una persona nació o no en una región en base a su nombre y apellido.

¿Cómo modificaría la respuesta para el punto (c) en caso de utilizar árboles de decisión en vez de KNN?

Ejercicio 9.5. Dada una base de personas con cuatro atributos (que se utilizará para predecir si se tomará o no vacaciones).

- **Ciudad** (con 1000 valores posibles - no tiene faltantes)
- **Provincia** (con 23 posibles valores - no tiene faltantes)
- **Edad** (valor numérico - no tiene valores faltantes)
- **Salario** (valor numérico - puede tener faltantes)

Sabemos además que no hay outliers – es decir valores atípicos en las columnas numéricas – y sabemos que las columnas numéricas no siguen una distribución normal. Responder:

1. ¿Si hubiera que escalar (a), completar valores (b) y convertir categóricas (c) en qué orden lo haría? Justifique
2. ¿Cuántas dimensiones quedarían en total si usamos One-Hot Encoding a las variables categóricas?
3. ¿Qué técnica de escalamiento elegiría?
4. Si tuviéramos que imputar número el salario y luego utilizáramos árboles de decisión al momento de predecir, qué estrategia elegiría (pueden ser varias) (a) imputar salario medio, (b) imputar “-1” (c) regresionar a partir de las otras (d) imputar salario medio y agregar una columna indicadora.