13. Predicción de secuencias (RNNs)

Notación (la misma de la clase): $\mathbf{x}_{\langle t \rangle}^{(k)} \in \mathbb{R}^p$ es la entrada de la k-ésima instancia (una secuencia) en el paso t; $\mathbf{h}_{\langle t \rangle}^{(k)} \in \mathbb{R}^H$, el estado oculto; $\mathbf{o}_{\langle t \rangle}^{(k)} \in \mathbb{R}^C$, la salida; y $\mathbf{y}_{\langle t \rangle}^{(k)}$, la etiqueta. U conecta la entrada con el estado oculto, W es la conexión recurrente y V conecta el estado oculto con la salida.

Ejercicio 13.1. Se tiene un conjunto de mensajes etiquetados con sentimiento positivo o negativo. Cada palabra de un mensaje se representa con un embedding de dimensión 100.

(a) Dibujar el esquema de una red neuronal recurrente (RNN) con **dos capas ocultas** que resuelva este problema, en dos versiones: compacta y desplegada en el tiempo. Indicar la dimensión de la entrada, de los estados ocultos y de la salida.

(b) ¿Qué función de pérdida corresponde usar? ¿Con qué función de activación en la salida?

(c) ¿En qué pasos de tiempo se aplica la función de pérdida? Si hay pasos en los que no se calcula la pérdida, ¿qué hacer con las salidas de esos pasos para no tener que cambiar el algoritmo de minimización?

Ejercicio 13.2. Dados los tipos de modelos vistos en clase: *uno a muchos*, *muchos a uno*, *muchos a muchos* y *muchos a muchos (desfasado)*, decidir cuál usar en cada uno de los siguientes casos. Justificar.

(a) Generar la descripción de un producto a partir de una foto del mismo.

(b) Predecir si una reseña de un producto es positiva o negativa.

(c) Traducir tickets de compra (por ejemplo, de español a inglés).

(d) Pronosticar la serie diaria de ventas del próximo mes a partir de los datos del último año.

(e) Generar recomendaciones de productos a partir de una categoría.

(f) Corregir la ortografía de una frase introducida por el usuario.

(g) Dado el audio largo de una conversación, predecir quién habla en cada segmento.

(h) Dado un libro, generar el audiolibro.

Ejercicio 13.3. Sea una RNN simple como la de la Figura 9. En cada paso t, la red recibe una entrada $\mathbf{x}_{\langle t \rangle}^{(k)} \in \mathbb{R}^p$, actualiza su estado oculto $\mathbf{h}_{\langle t \rangle}^{(k)} \in \mathbb{R}^H$ y produce una salida $\mathbf{o}_{\langle t \rangle}^{(k)} \in \mathbb{R}^C$, con matrices de pesos $U \in \mathbb{R}^{H \times p}$, $W \in \mathbb{R}^{H \times H}$ y $V \in \mathbb{R}^{C \times H}$.

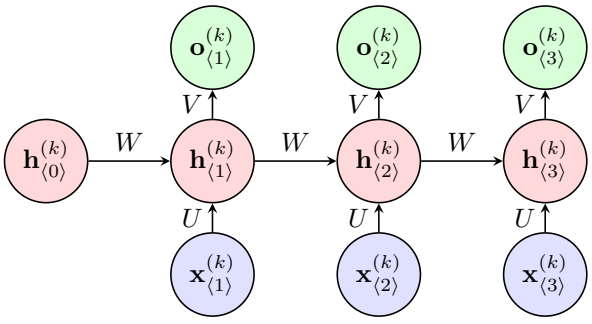


Figura 9: RNN desplegada en los pasos $t = 1, 2, 3$.

(a) Escribir las ecuaciones de la RNN (actualización del estado oculto y cálculo de la salida) en función de U, W y V. Suponer que todos los sesgos son nulos y que el estado oculto inicial es nulo ($\mathbf{h}_{\langle 0 \rangle}^{(k)} = \vec{0}$).

(b) Escribir la red como una composición de funciones para los tres primeros pasos ($t = 1, 2, 3$), mostrando cómo se calculan $\mathbf{o}_{\langle 1 \rangle}^{(k)}$, $\mathbf{o}_{\langle 2 \rangle}^{(k)}$ y $\mathbf{o}_{\langle 3 \rangle}^{(k)}$.

(c) Calcular los estados ocultos $\mathbf{h}_{\langle 1 \rangle}^{(k)}, \mathbf{h}_{\langle 2 \rangle}^{(k)}, \mathbf{h}_{\langle 3 \rangle}^{(k)}$ y las salidas $\mathbf{o}_{\langle 1 \rangle}^{(k)}, \mathbf{o}_{\langle 2 \rangle}^{(k)}, \mathbf{o}_{\langle 3 \rangle}^{(k)}$ para las entradas

$$\mathbf{x}_{\langle 1 \rangle}^{(k)} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{x}_{\langle 2 \rangle}^{(k)} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \quad \mathbf{x}_{\langle 3 \rangle}^{(k)} = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

con $p = H = C = 2$, todas las matrices de pesos iguales a la identidad,

$$U = W = V = I = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix},$$

y sin funciones de activación (operaciones puramente lineales).

(d) Escribir explícitamente la función a minimizar en función de U, W y V, si la pérdida es el error cuadrático, para una única instancia y usando sólo los dos primeros pasos, con etiquetas $\mathbf{y}_{\langle 1 \rangle}^{(k)}$ y $\mathbf{y}_{\langle 2 \rangle}^{(k)}$.

(e) Dibujar el grafo computacional de la RNN para esos dos pasos, incluyendo la función de pérdida. ¿Cuántas veces aparece W en el grafo? ¿Cómo se combinan esos aportes en el gradiente de W?

Ejercicio 13.4. Dada una RNN con entrada $\mathbf{x}_{\langle t \rangle}^{(k)} \in \mathbb{R}^p$, estado oculto $\mathbf{h}_{\langle t \rangle}^{(k)} \in \mathbb{R}^H$, salida $\mathbf{o}_{\langle t \rangle}^{(k)} \in \mathbb{R}^C$, matrices de pesos $U \in \mathbb{R}^{H \times p}$, $W \in \mathbb{R}^{H \times H}$ y $V \in \mathbb{R}^{C \times H}$, sesgos $b_h \in \mathbb{R}^H$ y $b_o \in \mathbb{R}^C$, función de activación tangente hiperbólica en el estado oculto, $\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$ (aplicada componente a componente), y salida lineal.

(a) Escribir las ecuaciones del estado oculto $\mathbf{h}_{\langle t \rangle}^{(k)}$ y de la salida $\mathbf{o}_{\langle t \rangle}^{(k)}$ en el paso t.

(b) Calcular el estado oculto y la salida en cada paso para $p = 3$, $H = 2$, $C = 1$ y los valores

$$\mathbf{x}^{(k)} = \left[\begin{pmatrix} 1 \\ 2 \\ 0 \end{pmatrix} \begin{pmatrix} 0 \\ 4 \\ 2 \end{pmatrix} \right], \quad \mathbf{h}_{\langle 0 \rangle}^{(k)} = \begin{pmatrix} 0 \\ 0 \end{pmatrix},$$

$$U = \begin{pmatrix} 0.1 & 0.2 & 0.3 \\ 0.4 & 0.5 & 0.6 \end{pmatrix}, \quad W = \begin{pmatrix} 0.7 & 0.8 \\ 0.9 & 1.0 \end{pmatrix}, \quad V = \begin{pmatrix} 1.1 & 1.2 \end{pmatrix}, \quad b_h = \begin{pmatrix} 0.1 \\ 0.2 \end{pmatrix}, \quad b_o = \begin{pmatrix} 0.3 \end{pmatrix}.$$

Para verificar: $\mathbf{h}_{\langle 1 \rangle}^{(k)} \approx \begin{pmatrix} 0.537 \\ 0.922 \end{pmatrix}$.

(c) Programar la cuenta anterior a partir del siguiente código base:

```
import numpy as np

x = [np.array([1, 2, 0]), np.array([0, 4, 2])]
h_0 = np.array([0, 0])

U = np.array([[0.1, 0.2, 0.3], [0.4, 0.5, 0.6]])
W = np.array([[0.7, 0.8], [0.9, 1.0]])
V = np.array([[1.1, 1.2]])

b_h = np.array([0.1, 0.2])
b_o = np.array([0.3])
```

Ejercicio 13.5. Arquitectura muchos a uno
Se clasifica el sentimiento de reseñas (positiva: $y = 1$, negativa: $y = 0$) con una RNN muchos a uno. Cada palabra es un embedding $\mathbf{x}_{\langle t \rangle}^{(k)} \in \mathbb{R}^2$, el estado oculto es $\mathbf{h}_{\langle t \rangle}^{(k)} = \tanh(W\mathbf{h}_{\langle t-1 \rangle}^{(k)} + U\mathbf{x}_{\langle t \rangle}^{(k)})$ con $\mathbf{h}_{\langle 0 \rangle}^{(k)} = \vec{0}$, y la predicción usa sólo el último estado: $\hat{y}^{(k)} = \sigma(V\mathbf{h}_{\langle T \rangle}^{(k)})$. Los parámetros son

$$U = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \qquad W = \begin{pmatrix} 0.5 & 0 \\ 0 & 0.5 \end{pmatrix}, \qquad V = \begin{pmatrix} 2 & -1 \end{pmatrix},$$

y los embeddings de las palabras son: *película* $= (0,\ 0.5)$, *muy* $= (0.5,\ 0)$, *buena* $= (1,\ 0)$.

(a) Dibujar la red desplegada para una reseña de 3 palabras, marcando qué salidas se calculan y cuál se usa en la pérdida. Indicar las dimensiones de U, W y V.

(b) Calcular $\hat{y}$ para la reseña "película muy buena" (positiva) y su entropía cruzada binaria.

(c) Para entrenar con *batches*, las reseñas más cortas se completan al final con vectores de ceros (*padding*) hasta la longitud de la más larga, $T = 5$. Calcular $\hat{y}$ si para "película muy buena" se toma $\mathbf{h}_{\langle 5 \rangle}^{(k)}$ en lugar de $\mathbf{h}_{\langle 3 \rangle}^{(k)}$. ¿Qué estado hay que usar para cada reseña?

(d) En lugar del último estado, se podría clasificar con el promedio de los estados, $\bar{\mathbf{h}}^{(k)} = \frac{1}{T}\sum_t \mathbf{h}_{\langle t\rangle}^{(k)}$. ¿Qué ventaja puede tener en reseñas largas? Pensar por dónde llega el gradiente a las primeras palabras.

(e) ¿Qué cambia en la arquitectura y en la pérdida si se quiere predecir la cantidad de estrellas (de 1 a 5)?

Ejercicio 13.6. Se modifica la RNN como muestra la Figura 10, donde las líneas punteadas son conexiones recurrentes (con el paso anterior).

(a) Escribir las fórmulas de la nueva arquitectura.

(b) ¿Qué ventajas y desventajas tiene frente a una RNN que sólo realimenta la salida del paso anterior ($W_1 = 0$)? ¿Y frente a una que sólo realimenta el estado oculto ($W_4 = 0$)?

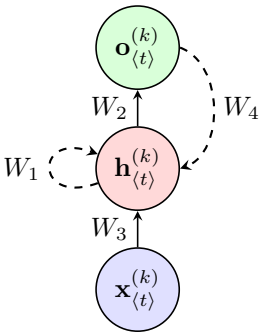


Figura 10: RNN con dos conexiones recurrentes (punteadas).

Ejercicio 13.7. Backpropagation through time (BPTT) a mano (opcional)
Una RNN escalar muchos a uno, con una sola instancia (se omite el superíndice (k)):

$$h_{\langle t\rangle} = \tanh(w\, h_{\langle t-1\rangle} + u\, x_{\langle t\rangle}), \qquad h_{\langle 0\rangle} = 0, \qquad o = v\, h_{\langle T\rangle}, \qquad J = (o-y)^2.$$

Se quiere el gradiente de J en el punto $u = 1$, $w = 0.5$, $v = 2$, para la secuencia $x_{\langle 1\rangle} = 1$, $x_{\langle 2\rangle} = 0.5$ ($T = 2$) con etiqueta $y = 1$. Datos: $\tanh(1) \approx 0.762$, $\tanh(0.881) \approx 0.707$ y $\tanh'(z) = 1 - \tanh^2(z)$.

(a) Dibujar el grafo computacional de J desplegado en el tiempo. ¿Qué parámetros aparecen más de una vez?

(b) **Forward:** calcular $h_{\langle 1\rangle}$, $h_{\langle 2\rangle}$, o y J.

(c) **Backward:** calcular $\frac{\partial J}{\partial v}$, $\frac{\partial J}{\partial w}$ y $\frac{\partial J}{\partial u}$. ¿Cómo se combinan los aportes de cada paso de tiempo?

(d) Para una secuencia de largo T, mostrar que $\frac{\partial h_{\langle T\rangle}}{\partial h_{\langle 1\rangle}} = \prod_{t=2}^{T} w\left(1 - h_{\langle t\rangle}^2\right)$.

(e) Como $0 < 1 - h_{\langle t\rangle}^2 \leq 1$, acotar $\left|\frac{\partial h_{\langle T\rangle}}{\partial h_{\langle 1\rangle}}\right|$ para $w = 0.5$ y $T = 20$. ¿Qué implica para aprender dependencias entre la primera y la última entrada? ¿Qué puede pasar si $|w| > 1$? Mencionar una técnica para cada problema.

Ejercicio 13.8. LSTM (opcional)
Una celda LSTM calcula en cada paso (sin sesgos, como en la clase):

$$\mathbf{i}_{\langle t\rangle}^{(k)} = \sigma(W^i \mathbf{h}_{\langle t-1\rangle}^{(k)} + U^i \mathbf{x}_{\langle t\rangle}^{(k)}) \qquad \mathbf{f}_{\langle t\rangle}^{(k)} = \sigma(W^f \mathbf{h}_{\langle t-1\rangle}^{(k)} + U^f \mathbf{x}_{\langle t\rangle}^{(k)})$$
$$\mathbf{g}_{\langle t\rangle}^{(k)} = \sigma(W^g \mathbf{h}_{\langle t-1\rangle}^{(k)} + U^g \mathbf{x}_{\langle t\rangle}^{(k)}) \qquad \tilde{\mathbf{C}}_{\langle t\rangle}^{(k)} = \tanh(W^{\tilde{C}} \mathbf{h}_{\langle t-1\rangle}^{(k)} + U^{\tilde{C}} \mathbf{x}_{\langle t\rangle}^{(k)})$$
$$\mathbf{C}_{\langle t\rangle}^{(k)} = \mathbf{f}_{\langle t\rangle}^{(k)} \odot \mathbf{C}_{\langle t-1\rangle}^{(k)} + \mathbf{i}_{\langle t\rangle}^{(k)} \odot \tilde{\mathbf{C}}_{\langle t\rangle}^{(k)} \qquad \mathbf{h}_{\langle t\rangle}^{(k)} = \mathbf{g}_{\langle t\rangle}^{(k)} \odot \tanh(\mathbf{C}_{\langle t\rangle}^{(k)})$$

(a) Si $\mathbf{x}_{\langle t\rangle}^{(k)} \in \mathbb{R}^p$ y $\mathbf{h}_{\langle t\rangle}^{(k)}, \mathbf{C}_{\langle t\rangle}^{(k)} \in \mathbb{R}^H$, ¿qué dimensiones tienen las matrices $W^{\cdot}$ y $U^{\cdot}$? Contar los parámetros de una capa LSTM, agregando un sesgo a cada compuerta y al candidato $\tilde{C}$, y compararla con una RNN simple de las mismas dimensiones. Calcular ambos para $p = 100$ (los embeddings del Ejercicio 13.1) y $H = 64$.

(b) ¿Entre qué valores están las compuertas $\mathbf{i}$, $\mathbf{f}$ y $\mathbf{g}$? ¿Qué pasa con el *cell state* si $\mathbf{f}_{\langle t\rangle}^{(k)} = \mathbf{1}$ e $\mathbf{i}_{\langle t\rangle}^{(k)} = \mathbf{0}$ en todos los pasos? ¿Y si $\mathbf{f}_{\langle t\rangle}^{(k)} = \mathbf{0}$?

(c) Considerando sólo el camino a través del *cell state*, mostrar que $\frac{\partial \mathbf{C}_{\langle t\rangle}^{(k)}}{\partial \mathbf{C}_{\langle t-1\rangle}^{(k)}} = \operatorname{diag}\left(\mathbf{f}_{\langle t\rangle}^{(k)}\right)$. Comparar con $\frac{\partial h_{\langle t\rangle}}{\partial h_{\langle t-1\rangle}}$ de la RNN simple (Ejercicio 13.7).

(d) Con $H = 1$, supongamos que en el primer paso $C_{\langle 1\rangle} = 0.8$ y que después $f_{\langle t\rangle} = 0.95$ e $i_{\langle t\rangle} = 0$ para $t = 2, \ldots, 20$. Calcular $C_{\langle 20\rangle}$ y $\frac{\partial C_{\langle 20\rangle}}{\partial C_{\langle 1\rangle}}$, y comparar con la cota del Ejercicio 13.7. ¿Por qué se dice que el *cell state* es la memoria de largo plazo?

Ejercicio 13.9. Generación de secuencias y *teacher forcing* (opcional)
Se quiere generar la descripción de una imagen (uno a muchos) con una RNN. La imagen se representa con un vector $\mathbf{x}^{(k)} \in \mathbb{R}^p$ y la descripción es una secuencia de palabras $\mathbf{y}^{(k)}_{\langle 1\rangle}, \ldots, \mathbf{y}^{(k)}_{\langle T\rangle}$ (vectores *one-hot* sobre un vocabulario de C palabras), que termina con la palabra especial `<END>`.

(a) La RNN espera una entrada en cada paso, pero la imagen es una sola. Escribir las ecuaciones del estado oculto para dos formas de completar la entrada de los pasos $t > 1$: (i) un vector de ceros; (ii) la palabra del paso anterior (con `<START>` en el primer paso, y la imagen como estado inicial $\mathbf{h}^{(k)}_{\langle 0\rangle}$). ¿Qué ventaja tiene (ii)?

(b) En (ii), durante el entrenamiento, ¿conviene usar como entrada del paso t la palabra que predijo la red en $t-1$ o la palabra real $\mathbf{y}^{(k)}_{\langle t-1\rangle}$ (*teacher forcing*)? ¿Qué pasa al principio del entrenamiento con la primera opción?

(c) En una RNN que sólo realimenta la salida, $\mathbf{h}^{(k)}_{\langle t\rangle} = g_1(W\mathbf{o}^{(k)}_{\langle t-1\rangle} + U\mathbf{x}^{(k)}_{\langle t\rangle})$, ¿qué cambia si se entrena con *teacher forcing*? ¿Hace falta BPTT? ¿Se pueden calcular todos los pasos en paralelo? ¿Y en una RNN con estado oculto?

(d) Al predecir no se conocen las etiquetas. ¿Qué entra a la red en cada paso y cuándo termina la generación? ¿Qué problema puede aparecer por entrenar con *teacher forcing* y predecir con las propias salidas?

Ejercicio 13.10. Diseñar una red encoder-decoder con RNNs que resuma textos. Dibujarla indicando qué entra al decoder en cada paso (durante el entrenamiento y al predecir) y cuándo termina la generación. Luego responder:

(a) ¿Qué tipo de red se usa en el encoder?

(b) ¿Y en el decoder?

(c) ¿Cómo se conecta el encoder con el decoder?

(d) ¿Se usa algún mecanismo de atención? ¿Por qué ayuda en este problema?

(e) ¿Las redes usadas leen la entrada de manera secuencial?

(f) ¿Se podrían usar redes que lean la entrada de manera bidireccional? ¿En el encoder, en el decoder o en ambos?

(g) ¿Existen redes que lean toda la entrada al mismo tiempo?

(h) ¿Hay algún límite en el tamaño de la entrada?

Ejercicio 13.11. Atención en un encoder-decoder
Un decoder con atención de Luong (score: producto punto) traduce una oración de 3 palabras. Los estados del encoder y el estado actual del decoder son:

$$h_{\langle 1\rangle} = \begin{pmatrix} 2 \\ 0 \end{pmatrix}, \quad h_{\langle 2\rangle} = \begin{pmatrix} 0 \\ 2 \end{pmatrix}, \quad h_{\langle 3\rangle} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \qquad s_{\langle t\rangle} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}.$$

Datos: $e \approx 2.718$, $e^2 \approx 7.389$.

(a) Calcular los scores $e_{\langle t,i\rangle} = s_{\langle t\rangle}^\top h_{\langle i\rangle}$.

(b) Calcular los pesos de atención $\alpha_{\langle t,i\rangle} = \mathrm{softmax}_i(e_{\langle t,i\rangle})$. ¿Cuánto suman? ¿A qué palabra de la entrada "presta más atención" el decoder en este paso?

(c) Calcular el vector de contexto $c_{\langle t\rangle} = \sum_i \alpha_{\langle t,i\rangle} h_{\langle i\rangle}$. ¿Qué dimensión tiene?

(d) La predicción se calcula como $\tilde{s}_{\langle t\rangle} = \tanh(W_c[\,c_{\langle t\rangle};\, s_{\langle t\rangle}\,])$ y $p(o_{\langle t\rangle} \mid \cdot) = \mathrm{softmax}(W_s \tilde{s}_{\langle t\rangle})$, donde $[\,\cdot\,;\,\cdot\,]$ es la concatenación. Escribir el vector $[\,c_{\langle t\rangle};\, s_{\langle t\rangle}\,]$. Si $\tilde{s}_{\langle t\rangle} \in \mathbb{R}^2$ y el vocabulario de salida tiene C palabras, ¿qué dimensiones tienen W_c y W_s?

(e) Si $s_{\langle t\rangle}$ fuese ortogonal a todos los $h_{\langle i\rangle}$, ¿cuánto valdrían los pesos y el contexto?

(f) ¿Qué pasa con los pesos si todos los scores se multiplican por 10? ¿Y si se dividen por 10?

(g) Sin atención, el decoder recibe sólo el último estado del encoder, $c = h_{\langle 3\rangle}$. ¿Por qué eso es un cuello de botella en oraciones largas? ¿Cómo lo resuelve la atención?

(h) En la atención de Bahdanau el score usa $s_{\langle t-1\rangle}$ en lugar de $s_{\langle t\rangle}$. ¿Por qué? (Pista: pensar dónde se usa $c_{\langle t\rangle}$ en cada versión).