14. Redes Convolucionales

Importante - En esta guía llamamos *convolución* (*), *Conv1D* o *Conv2D* a la operación vista en la teórica (la convolución en el sentido del aprendizaje automático), que en realidad es la *cross-correlation* (correlación cruzada) clásica. Para más detalles ver este video. Usamos la terminología de la clase: *filtro* (o *kernel*), *salto* (*stride*), *padding* y *mapa de activación* (la salida de un filtro).

Ejercicio 14.1. Invarianza y equivarianza
Una función f que procesa imágenes es **invariante** a una transformación t si $f(t(I)) = f(I)$ para toda imagen I, y **equivariante** si $f(t(I)) = t(f(I))$, es decir, si su salida (una posición o una imagen) se transforma igual que la imagen. Para mostrar que no lo es alcanza con un contraejemplo.
Consideramos tres transformaciones: t_1 traslada la imagen un píxel a la derecha con padding 0 (la última columna se pierde), t_2 hace lo mismo con padding circular (la última columna pasa a ser la primera) y r la rota $90°$ en sentido horario. Aplicadas a una imagen de ejemplo (en negrita, el píxel más brillante):

$$I = \begin{pmatrix} 1 & 0 & 2 \\ 0 & 3 & \mathbf{5} \\ 4 & 0 & 0 \end{pmatrix} \qquad t_1(I) = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 3 \\ 0 & 4 & 0 \end{pmatrix} \qquad t_2(I) = \begin{pmatrix} 2 & 1 & 0 \\ \mathbf{5} & 0 & 3 \\ 0 & 4 & 0 \end{pmatrix} \qquad r(I) = \begin{pmatrix} 4 & 0 & 1 \\ 0 & 3 & 0 \\ 0 & \mathbf{5} & 2 \end{pmatrix}$$

Por ejemplo, la suma f_1 no es invariante a t_1: $f_1(I) = 15$ pero $f_1(t_1(I)) = 8$. En cambio, la posición del píxel más brillante f_3 es equivariante a t_2: el 5 se mueve una columna a la derecha (y da la vuelta) igual que el resto de la imagen, y eso pasa con cualquier imagen.

(a) Completar la tabla con *invariante*, *equivariante* o *ninguna*, justificando con un argumento general o con un contraejemplo. Suponer que f_4 y f_5 siempre aciertan.

	t_1	t_2	r
f_1: suma de las intensidades	ninguna		
f_2: intensidad máxima			
f_3: posición del píxel más brillante		equivariante	
f_4: ¿hay al menos una persona? (booleano)			
f_5: máscara de segmentación			

(b) ¿Qué propiedad conviene para clasificar (como f_4) y cuál para segmentar (como f_5)? Una capa convolucional es equivariante a traslaciones (salvo en los bordes): ¿qué capas de una CNN aportan invarianza?

Ejercicio 14.2. Filtros y pooling Considerar la imagen X (6×6), un cuadrado claro sobre un fondo oscuro, y el filtro W (3×3):

$$X = \begin{pmatrix} 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 1 & 1 & 1 & 0 \\ 0 & 1 & 1 & 1 & 1 & 0 \\ 0 & 1 & 1 & 1 & 1 & 0 \\ 0 & 1 & 1 & 1 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} \qquad W = \begin{pmatrix} 1 & 0 & -1 \\ 1 & 0 & -1 \\ 1 & 0 & -1 \end{pmatrix}$$

(a) ¿Qué tamaño tiene $Y = X * W$ (salto 1, sin padding)? Calcular Y.

(b) ¿Qué detecta el filtro? ¿Qué indica el signo de cada valor? ¿Por qué no aparecen los bordes de arriba y de abajo del cuadrado?

(c) Aplicar a Y max pooling y average pooling de 2×2 con salto 2. ¿Qué tamaño tiene la salida? ¿Qué información sobre los bordes conserva cada uno y cuál pierde?

(d) ¿Qué filtro detectaría los bordes horizontales?

Ejercicio 14.3. Considerar la salida intermedia A de una capa oculta de una red convolucional que procesa imágenes, con C mapas de activación de $H \times W$ (es decir, A tiene tamaño $H \times W \times C$). Diseñar una capa convolucional con un único filtro fijo (sesgo 0 y activación identidad) cuya salida B tenga tamaño $H \times W \times 1$ y tal que $B(i, j, 0)$ sea el promedio de los C valores de A en la posición (i, j). ¿Qué tamaño tiene el filtro y cuáles son sus pesos? ¿Qué salto y qué padding se eligieron para la capa?

Ejercicio 14.4. Responder según corresponda. Todas las triplas son (*alto* $\times$ *ancho* $\times$ *canales*):

1. Dada una entrada de tamaño $(32 \times 32 \times 16)$, ¿cuál será el tamaño de la salida luego de aplicar max pooling de 2×2 con salto 2?
2. Queremos aplicar filtros de 7×7 con salto 1 a una entrada de $(63 \times 63 \times 16)$. ¿Qué padding hay que usar para mantener el alto y el ancho de la entrada?
3. ¿Qué salto estamos usando si al aplicar filtros de 5×5 con padding 1 a una imagen de $(123 \times 123 \times 3)$ obtenemos una salida de $(41 \times 41 \times 20)$? ¿Y cuántos filtros se usaron?
4. A una imagen de $(64 \times 64 \times 3)$ se le aplican varias capas convolucionales seguidas, con filtros de 3×3, salto 1 y sin padding. ¿Qué pasa con su alto y su ancho a medida que se agregan capas?
5. A un mapa de $(28 \times 28 \times 512)$ se le aplica global average pooling. ¿Qué tamaño tiene la salida?

Ejercicio 14.5. Campo receptivo Se tiene una red con dos capas convolucionales seguidas:

1. Conv2D con filtro de 3×3, padding 1 y salto 1.
2. Conv2D con filtro de 5×5, padding 0 y salto 1.

Responder:

1. Para un píxel de la salida final (capa 2), dibujar esquemáticamente su campo receptivo en la entrada original.
2. Calcular el tamaño (alto $\times$ ancho) de ese campo receptivo.
3. Repetir el ejercicio con salto 2 en la primera capa. ¿Cómo afecta esto al tamaño del campo receptivo?
4. Explicar cómo influye cada parámetro de una capa convolucional (tamaño del filtro, salto y padding) en el crecimiento del campo receptivo.

Ejercicio 14.6. Considerar una red neuronal convolucional que se utiliza para clasificar imágenes en diez clases. La tabla 4 describe la estructura de la red. Completar la tabla con el número de parámetros entrenables de cada capa. Todas las convoluciones usan padding para conservar el alto y el ancho de las imágenes.

Número de Capa	**Propiedades de la Capa**	**Cantidad de Parámetros**
Capa 0	Imágenes en color de 32x32 y 3 canales	0
Capa 1	Capa convolucional con 40 filtros de 3x3	
Capa 2	Capa convolucional con 40 filtros de 3x3	
Capa 3	Max pooling de 2x2 con salto 2	
Capa 4	Capa convolucional con 64 filtros de 3x3	
Capa 5	Capa convolucional con 64 filtros de 3x3	
Capa 6	Aplanado (*flatten*)	
Capa 7	Capa densa con 128 neuronas	
Capa 8	Capa de salida densa con 10 neuronas	
	TOTAL:	

Tabla 4: Descripción de la estructura de una red neuronal convolucional y la cantidad de parámetros entrenables asociados a cada capa. El salto de cada capa es 1 salvo que se aclare.

Luego:

(a) ¿Qué capa concentra la mayor parte de los parámetros?

(b) Si se reemplaza el aplanado por global average pooling, ¿cuántos parámetros tiene la red?

(c) ¿Cuántos parámetros tendría una capa densa de 40 neuronas aplicada directamente a la imagen aplanada? Comparar con la capa 1. ¿Qué aprovecha la convolución para necesitar tan pocos?

Ejercicio 14.7. Dada la señal unidimensional de entrada $x = (0, 1, 1, 1, 0, 0, 0, 1, 1, 1, 0, 0, \ldots)$, que se repite con período 6, con $t = 0, 1, 2, \ldots$, y el filtro 1D $w = (-1, 0, 1)$, resolver:

1. Graficar la señal de entrada. Calcular la salida $y = x * w$ (el mapa de activación) de una convolución 1D sin padding y con salto 1, usando los primeros 12 valores de la entrada ($t = 0, \ldots, 11$). ¿Qué tamaño tiene la salida? ¿Y si la entrada tiene largo N?
2. Interpretar brevemente los valores de la señal de salida y en relación con la detección de características en x: ¿qué relación hay entre la salida de la convolución y la señal?

Ejercicio 14.8. Verdadero o Falso:

(a) Una capa de max pooling reduce el alto y el ancho de los mapas de activación, pero no la cantidad de canales.

(b) Una capa de max pooling tiene parámetros entrenables.

(c) Una capa convolucional con un filtro de 3×3 tiene un total de 9 pesos más 1 sesgo, independientemente de las dimensiones de la imagen a la cual se le aplica.

(d) Dos capas convolucionales de 3×3 seguidas (salto 1) tienen el mismo campo receptivo que una de 5×5, y menos parámetros.

(e) El global average pooling toma el valor medio de cada mapa de activación completo y lo usa como una entrada a la capa densa, reduciendo significativamente el número de parámetros.

(f) El global pooling permite que una misma arquitectura procese imágenes de distintas dimensiones/resoluciones.

Ejercicio 14.9. (opcional) **Convolución depthwise separable**
Una capa convolucional recibe un mapa de $32 \times 32 \times 64$ y devuelve uno de $32 \times 32 \times 128$, con filtros de 3×3, padding 1 y salto 1.

(a) ¿Cuántos parámetros tiene si es una convolución estándar?

(b) Reemplazarla por una convolución depthwise separable: primero un paso *depthwise* (un filtro de 3×3 por canal, que filtra cada canal por separado) y después uno *pointwise* (filtros de $1 \times 1 \times 64$, que mezclan los canales en cada píxel). ¿Cuántos filtros tiene cada paso y qué tamaño tiene su salida? ¿Cuántos parámetros hay en total?

(c) Mostrar que, sin contar sesgos, la cantidad de parámetros de la separable dividida la de la estándar es $\frac{1}{K} + \frac{1}{F^2}$, con K filtros de $F \times F$. ¿Cuántas veces menos parámetros tiene en este caso?

(d) ¿Qué filtros puede aprender la convolución estándar que la separable no puede?

Ejercicio 14.10. Diseñar la salida de un detector
Una cámara detecta a lo sumo una cara por imagen. Para cada imagen se quiere saber si hay una cara, si la persona usa anteojos, la caja de la cara y la posición de los dos ojos.

(a) Armar el vector $\mathbf{y}$ que debe predecir la red.

(b) ¿Qué función de activación y qué pérdida corresponden a cada parte de $\mathbf{y}$? ¿Cuáles se calculan si no hay cara?

(c) Si la cara está de perfil, puede verse un solo ojo. ¿Cómo hay que cambiar $\mathbf{y}$ y la pérdida?

(d) En lugar de hay_cara y usa_anteojos, ¿se podría usar un softmax sobre tres clases (fondo, cara sin anteojos y cara con anteojos)? ¿Qué cambia en la pérdida? ¿Qué pasaría si hubiera que predecir varios atributos sí/no además de los anteojos?

(e) Para detectar varias caras, se divide la imagen en una grilla y cada celda predice un vector como el de (a) para la cara cuyo centro cae en ella. ¿Qué tamaño tiene la salida con una grilla de 13×13? ¿Qué pasa si los centros de dos caras caen en la misma celda?

Ejercicio 14.11. (opcional) **IoU, non-max suppression y evaluación**
En una imagen hay dos perros, con cajas reales $A = (10, 10, 50, 50)$ y $B = (60, 0, 100, 30)$, escritas como (x_0, y_0, x_1, y_1) en píxeles. Un detector predice tres cajas, todas de la clase perro:

Caja	(x_0, y_0, x_1, y_1)	**Confianza**
P_1	$(10, 20, 50, 60)$	0.9
P_2	$(15, 20, 55, 60)$	0.7
P_3	$(60, 60, 90, 80)$	0.6

(a) Calcular el IoU de cada caja predicha con A y con B.

(b) Aplicar non-max suppression con umbral 0.5: ordenar las cajas por confianza, quedarse con la de mayor confianza, descartar las que tienen IoU ≥ 0.5 con ella y repetir con las restantes. ¿Qué cajas quedan?

(c) Con un umbral de IoU de 0.5, clasificar las cajas que quedan en TP o FP y contar los FN. Calcular la precision y el recall.

(d) ¿Qué habría pasado con P_2 si no se aplicaba non-max suppression?

(e) Una caja real chica, $(0, 0, 10, 10)$, se predice como $(5, 0, 15, 10)$, y una grande, $(0, 0, 100, 100)$, como $(5, 0, 105, 100)$. Comparar la MSE de las coordenadas y el IoU de cada predicción. ¿Cuál mide mejor la calidad de la caja?

(f) Si se entrenara con $\text{Loss}_{\text{IoU}} = 1 - \text{IoU}$, ¿cuánto vale la pérdida de P_3 respecto de B? ¿Qué información aporta su gradiente para acercar la caja?

Ejercicio 14.12. Segmentación semántica
Se quiere segmentar imágenes de $128 \times 128 \times 3$ en $C = 3$ clases (cielo, pasto y vaca), es decir, asignarle una clase a cada píxel.

(a) Con una red totalmente convolucional (sin capas densas), ¿qué tamaño tiene la salida? ¿Qué función de activación se aplica a la salida, sobre qué eje, y qué pérdida se usa? ¿Cómo se obtiene la clase predicha de cada píxel?

(b) ¿Qué ventajas tiene no usar capas densas? Pensar en el tamaño de la imagen de entrada.

(c) Mantener 128×128 en todas las capas es caro en memoria y cómputo. Una U-Net baja la resolución en el encoder con 4 max pooling de 2×2 con salto 2. ¿Qué alto y ancho tiene el mapa más chico?

(d) El decoder recupera la resolución con convoluciones transpuestas, cuya salida mide $O = s(I - 1) + F - 2P$. ¿Qué tamaño da una convolución transpuesta de 2×2 con salto 2 y sin padding sobre un mapa de 8×8? ¿Cuántas hacen falta para volver a 128×128?

(e) ¿Qué condición tienen que cumplir el alto y el ancho de la entrada para que los mapas del encoder y del decoder midan lo mismo en cada nivel y se puedan concatenar (*skip connections*)?

Ejercicio 14.13. (opcional) **Skip connections en la U-Net**
Una U-Net 1D muy simplificada segmenta una fila de 8 píxeles. El encoder aplica dos veces max pooling de tamaño 2 y salto 2 ($8 \to 4 \to 2$). El decoder recupera el tamaño con dos convoluciones transpuestas de tamaño 2, salto 2 y pesos $(1, 1)$, que repiten cada valor dos veces ($2 \to 4 \to 8$).

(a) Calcular el cuello de botella (el mapa más chico) y la salida para $x = (0, 0, 0, 1, 1, 1, 1, 1)$, cuya máscara correcta es x. ¿Qué pasa con el borde?

(b) Encontrar otra entrada, con otra máscara, que dé el mismo cuello de botella. ¿Puede algún decoder, por bien entrenado que esté, segmentar bien las dos?

(c) Con *skip connections*, el decoder recibe además, concatenado como otro canal, el mapa del encoder del mismo tamaño. ¿Qué información le devuelve? ¿Por qué no alcanza con usar sólo los mapas de alta resolución, sin bajar?